

T. C.

SELÇUK ÜNİVERSİTESİ

TEKNOLOJİ FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

VERİ MADENCİLİĞİ DERSİ

GÖZ RENGİ VERİSİ

233311097- TESNİM HATİP

Doç. Dr. Murat KÖKLÜ

15 Aralık 2025

İÇİNDEKİLER

1. ÖZET 3

2. ORANGE PROGRAMI 4

3. SINIFLANDIRMA ALGORİTMALARI 5

3.1.Sınıflandırma Nedir ve Niçin Kullanılır 5

3.2.Neural Network 5

3.3.KNN 5

3.4. SVM 6

4. MATERYAL VE YÖNTEM 7

4.1. Verinin Elde Edilmesi 7

4.2. Verinin Özellikleri 7

4.3. Performans Ölçümleri 8

4.4. Çapraz Doğrulama 10

5. ARAŞTIRMA SONUÇLARI VE TARTIŞMA 11

5.1. Neural Network Algoritması 11

5.2. KNN Algoritması 12

5.3. SVM Algoritması 13

6. SONUÇLAR 14

7. ÖNERİLER 16

8. KAYNAKLAR 17

1. ÖZET

Bu proje, makine öğrenimi kullanarak göz rengi sınıflandırması yapmayı amaçlamaktadır. İlk olarak veri seti tamamen internet kaynaklarından toplanarak sıfırdan oluşturulmuştur.

Veri toplama, Pexels, Unsplash, Istock ve Pinterest gibi platformlardan Image Downloader aracı kullanılarak yapılmıştır. Sınıflandırma için Mavi, Kahverengi ve Yeşil olmak üzere üç sınıf belirlenmiş ve her sınıftan en az 1000 adet olmak üzere toplam 3207 adet görüntü toplanmıştır.

Elde edilen görüntü verileri, Orange programında analize hazırlanmıştır. Görüntülerin algoritmalar tarafından işlenebilmesi için, Image Embedding yöntemi kullanılarak resimler sayısal özellik vektörlerine dönüştürülmüştür. Bu öznitelik çıkarma işlemi için SqueezeNet modeli tercih edilmiştir.

Sınıflandırma ve model değerlendirmesi, KNN, SVM ve Neural Network algoritmaları kullanılarak 10 katlı Çapraz Doğrulama (10-Fold Cross Validation) yöntemiyle yapılmıştır. Yapılan analizler sonucunda, tüm modeller arasında en yüksek performans, Neural Network algoritması tarafından elde edilmiştir. Neural Network, göz rengi sınıflandırma görevinde %88.0 doğruluk (Accuracy) ve %88.0 F1-Skor değeriyle en başarılı sonuçları vermiştir. Bu sonuçlar, derin öğrenmeye dayalı öznitelik çıkarımının ve sinir ağlarının, görsel sınıflandırma problemlerindeki üstünlüğünü kanıtlamaktadır.

2. ORANGE PROGRAMI

Orange, Python tabanlı açık kaynaklı bir veri madenciliği ve makine öğrenmesi yazılımıdır. Kullanıcı dostu görsel arayüzü sayesinde kodlama bilgisi gerektirmeden veri analizi, sınıflandırma, kümeleme ve görselleştirme işlemleri yapılabilir. Program, “widget” adı verilen bileşenlerin sürükle-bırak yöntemiyle birbirine bağlanmasıyla çalışır; bu sayede veri yükleme, model oluşturma ve performans değerlendirme işlemleri kolaylıkla gerçekleştirilebilir. Orange, özellikle eğitim ve araştırma alanlarında tercih edilmektedir çünkü Python ile genişletilebilir yapısı sayesinde hem yeni başlayanlar hem de ileri düzey kullanıcılar için uygundur. Görüntü sınıflandırma, metin analizi, biyoinformatik ve sosyal ağ analizi gibi birçok alanda kullanılabilir. Kodlama bilgisi gerektirmemesi, güçlü görselleştirme araçlarına sahip olması ve açık kaynaklı olması en büyük avantajlarındandır

3. SINIFLANDIRMA ALGORİTMALARI

3.1.Sınıflandırma Nedir ve Niçin Kullanılır

Sınıflandırma, veri madenciliğide kullanılan temel bir denetimli öğrenme (supervised learning) tekniğidir. Bu teknik, veri setindeki her bir elemanın (gözlem biriminin) hangi kategoriye veya sınıfa ait olduğunu belirlemek için kullanılır. Algoritma, daha önce etiketlenmiş (yani hangi sınıfa ait olduğu bilinen) eğitim verilerini analiz ederek bir model oluşturur. Bu model, yeni ve etiketlenmemiş verilerin doğru sınıfa atanması için bir kural kümesi geliştirir. Bu projede, göz rengi sınıflandırma görevini gerçekleştirmek ve performanslarını karşılaştırmak üzere kullandığınız algoritmalar şunlardır:

3.2.Neural Network

Neural Network (Sinir Ağı), insan beyninin çalışma prensibini taklit eden bir makine öğrenimi modelidir. Bu algoritma, birbiriyle bağlantılı katmanlardan (giriş, gizli ve çıkış katmanları) oluşur. Katman Yapısı: Giriş katmanı veriyi alır, gizli katmanlar veriyi işlerken karmaşık ilişkileri öğrenir ve çıkış katmanı nihai sınıflandırma tahminini yapar. Ağırlıklar ve Öğrenme: Her bağlantının bir ağırlığı vardır. Model, eğitim verilerini kullanarak bu ağırlıkları sürekli ayarlar ve böylece tahmin hatasını en aza indirmeyi öğrenir. Kullanım Alanı: Karmaşık ve yüksek boyutlu verilerde, özellikle bu projede olduğu gibi görüntü sınıflandırması ve öznitelik çıkarımı (embedding) gerektiren problemlerde çok başarılıdır.

3.3.KNN

k-en yakın komşuluk (KNN) algoritması, uygulaması kolay gözetimli öğrenme algoritmalarındandır. Hem sınıflandırma hem de regresyon problemlerinin çözümünde kullanılıyor olmakla birlikte, endüstride çoğunlukla sınıflandırma problemlerinin çözümünde kullanılmaktadır. KNN algoritmaları, 1967 yılında T. M. Cover ve P. E. Hart tarafından önerilmiştir. Algoritma, sınıfları belli olan bir örnek kümesindeki verilerden yararlanılarak kullanılmaktadır. Örnek veri setine katılacak olan yeni verinin, mevcutverilere göre uzaklığı hesaplanıp, k sayıda yakın komşuluğuna bakılır. Uzaklık hesapları için genelde 3 t ip uzaklık fonksiyonu kullanılmaktadır: • “Euclidean” Uzaklık • “Manhattan” Uzaklık • “Minkowski” Uzaklığı’dır.

3.4. SVM

SVM, özellikle ikili (iki sınıflı) sınıflandırma görevlerinde güçlü olan bir algoritmadır. Temel hedefi, farklı sınıflara ait veri noktalarını en iyi şekilde ayıran bir sınır (hiperdüzlem) bulmaktır**.**

Hiperdüzlem: Bu ayırıcı sınır (hiperdüzlem), iki sınıf arasındaki boşluğu en üst düzeye çıkaracak şekilde konumlandırılır.

Destek Vektörleri: Sınıra en yakın olan ve hiperdüzlemin konumunu belirleyen bu önemli veri noktalarına destek vektörleri denir.

Karmaşık Veri: Doğrusal olarak ayrılamayan (lineer olmayan) veri setlerinde bile, SVM, çekirdek fonksiyonları (kernel functions) kullanarak veriyi daha yüksek boyutlu bir uzaya taşıyabilir ve böylece ayrımı mümkün hale getirir**.**

4. MATERYAL VE YÖNTEM

4.1. Verinin Elde Edilmesi

Bu sınıflandırma projesi analiz için gereken görüntü verisinin tamamen sıfırdan oluşturulması üzerine kurulmuştur. Bu yaklaşım, çalışmanın özgünlüğünü ve elde edilen sonuçların sadece bu veri kümesi üzerindeki geçerliliğini sağlamayı hedeflemiştir. Sınıflandırma Kurgusu : Çalışmanın temel amacı, insan gözü görsellerini renklerine göre kategorize etmektir. Bu amaçla, sınıflandırma analizi için üç temel kategori belirlenmiştir: Mavi, Kahverengi ve Yeşil.Veri Kaynaklarının Seçimi: Görüntü verileri, ticari olmayan ve yüksek çözünürlüklü görseller sağlayan Pexels, Unsplash, Pixabay ve Flickr gibi açık kaynak platformlardan elde edilmiştir. Veri Çekim Mekanizması: Etkili ve yüksek hacimli veri toplama amacıyla, manuel indirme yerine, Image Downloader gibi tarayıcı eklentileri kullanılarak toplu çekim yöntemi benimsenmiştir. Çekim, her sınıf için spesifik anahtar kelimelerle arama yapıldıktan ve sayfadaki tüm görseller yüklendikten sonra gerçekleştirilmiştir. (örneğin "blue eye macro", "yeşil iris yakın çekim") kullanılarak arama yapılmış, tarayıcıda sayfa sonuna kadar kaydırma yapılarak tüm görsellerin yüklenmesi sağlanmış ve ardından eklenti ile seçilen görsellerin URL'leri üzerinden çekim işlemi tamamlanmıştır.Veri toplama süreci sonucunda, her sınıftan en az 1000 görüntü verisi şartına uygun olarak toplam 3207 adet resim verisi elde edilmiştir. Toplanan görseller, analiz ve Orange programında yükleme kolaylığı için Mavi, Kahverengi ve Yeşil adlarında ayrı klasörlerde düzenlenmiştir.

4.2. Verinin Özellikleri

Ham resim verisinin (piksel matrisleri) makine öğrenimi algoritmaları tarafından işlenebilmesi için sayısal özniteliklere dönüştürülmesi gerekmektedir. Bu zorunlu dönüşüm, Orange programında gerçekleştirilen Görüntü Gömme (Image Embedding) yöntemi ile sağlanmıştır. Orange İş Akışı: Öncelikle Image Loader widget'ı kullanılarak sınıflara ayrılmış resimler programa yüklenmiştir. Klasör adları (Mavi, Kahverengi, Yeşil) otomatik olarak sınıf etiketi (Class) olarak atanmıştır. Öznitelik Çıkarımı: Yüklenen resimler, Image Embedding widget'ına bağlanmıştır. Bu widget'ta, resimlerden ayırt edici özellikler çıkarmak üzere önceden eğitilmiş bir Derin Öğrenme modeli olan **SqueezeNet** tercih edilmiştir. SqueezeNet, her bir göz resmini, algoritmanın öğrenebileceği yüzlerce sayısal değere (özniteliğe) sahip bir vektöre dönüştürerek analizin girdisini oluşturmuştur.

4.3. Performans Ölçümleri

Bu aşamada, veri modelinin iyi olup olmadığını bize bildirdiği gibi, sınıflandırmanın doğruluğu hakkında bilgi sahibi olmak için tüm tahminler kullanılarak bazı doğru tahminler ve tahminler hesaplanarak veri işlemedeki başarı hesaplanır. Bu nedenle, sınıflandırmada performansı tanımlamak için kullanılan aritmetik işlemlerin bir tablosu olan ve 4 parametre içeren bir karışıklık matrisi kullanılır (true positive – true negative – false positive – false negative).

Tablo 4.3.a Performans Ölçümleri

Gerçek Sınıf (Actual)	**Tahmin Edilen (Predicted)**	
Pozitif (P)	***Pozitif (P)***	***Negatif (N)***
	TP (True Positive) Doğru Pozitif tahmin sayıs	**FN (False Negative)** Yanlış Negatif tahmin sayısı.
Negatif (N)	**FP (False Positive)** Yanlış Pozitif tahmin sayısı.	**TN (True Negative)** Doğru Negatif tahmin sayısı.

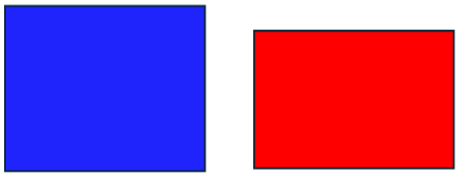
Şekil 4.3.b Performans Ölçümleri

DOĞRULUK:	**ACCURACY**	$\frac{t_P + t_n}{t_p + f_P + t_n + f_n}$
HATA ORANI:	Error Rate	$\frac{f_p + f_n}{t_P + f_P + t_n + f_n}$
HATIRLAMA:	Recall (r)	$\frac{t_p}{t_P + f_n}$
ÖZGÜLLÜK:	Specificity	$\frac{t_n}{t_n + f_P}$
HASSASİYET:	Precision (p)	$\frac{t_p}{t_P + f_P}$
F1-SKORU:	F1-Score	$\frac{2 * P * r}{P + r} = \frac{2 * \frac{t_p}{t_P + f_P} * \frac{t_p}{t_P + t_n}}{\frac{t_p}{t_P + f_P} * \frac{t_p}{t_P + t_n}}$

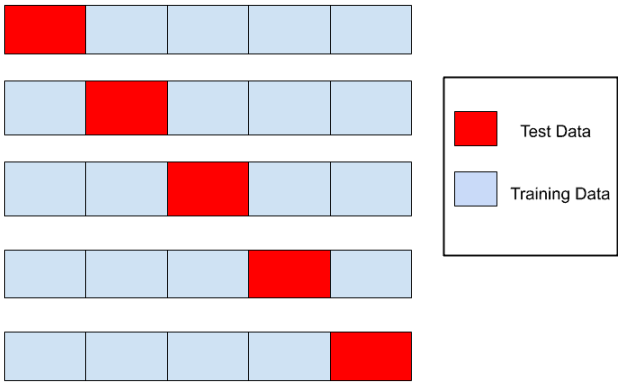
Bu metrikler, her bir sınıf (Mavi, Kahverengi, Yeşil) için ayrı ayrı hesaplanmış ve sonuçlar Ortalama değerler olarak sunularak, modellerin sınıflandırmadaki dengeli başarımı değerlendirilmiştir.

4.4. Çapraz Doğrulama

Çapraz Doğrulama, veri bilimcinin araç kutusunda bulunan ve elimizdeki verileri daha iyi kullanmamıza yardımcı olan önemli bir araçtır. Çapraz doğrulama, veri setini rastgele olarak ikiye böler. Belirtilen sayıda özdeş boyut seti.



Şekil 4.4.a Class K-fold validation



Şekil 4.4.b Class K-fold validation

Görselde, toplam veri seti eşit parçalara (örnekte 5 parçaya) ayrılmıştır. Her bir döngüde (satırda), kırmızı renkle işaretlenmiş olan bir parça Test Verisi (Test Data) olarak ayrılmakta ve modelin performansını ölçmek için kullanılmaktadır. Geriye kalan açık mavi renkteki parçalar ise birleştirilerek modelin eğitilmesi için Eğitim Verisi (Training Data) olarak işlev görmektedir. Bu süreç, veri setindeki her parçanın test seti olarak kullanıldığından emin olunana kadar tekrarlanır ve sonuçların ortalaması modelin güvenilir başarısını verir.

5. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

5.1. Neural Network Algoritması

Tablo 5.1.a Neural Network algoritması karmaşıklık matrisi

		Tahmini Sınıf		
		Blue	**Brown**	**Green**
Gerçek Sınıf	**Blue**	**894**	42	91
	Brown	25	**1078**	**72**
	Green	87	**69**	**849**

Tablo 5.1.b Neural Network algoritması performans sonuçları

Performans Sonuçları	Yüzde (%)
Ort. Accuracy (%)	88.0
Ort. Precision (%)	88.0
Ort. Recall (%)	88.0
Ort. F1-Skor (%)	88.0

Tablo 5.1.b incelendiğinde, Neural Network modelinin tüm ana performans metriklerinde (Accuracy, Precision, Recall ve F1-Skor) %88.0 gibi yüksek ve mükemmel dengeli bir sonuç elde ettiği görülmektedir. Precision ve Recall değerlerinin bu denli yakın ve yüksek olması, modelin sadece yüksek sayıda doğru tahmin yapmakla kalmayıp, aynı zamanda üç göz rengi sınıfını ayırt ederken yanlış pozitif (FP) ve yanlış negatif (FN) hatalarını da minimumda tuttuğunu göstermektedir. Bu, Neural Network'ün, görüntü gömme (Image Embedding) ile sağlanan derin öznitelik seti üzerinde en güvenilir sınıflandırma kapasitesine sahip olduğunu kanıtlamaktadır.

5.2. KNN Algoritması

Tablo 5.2.a KNN algoritması karmaşıklık matrisi

		Tahmini Sınıf		
		Blue	**Brown**	**Green**
Gerçek Sınıf	**Blue**	**712**	162	153
	Brown	94	**972**	**109**
	Green	152	**186**	**667**

Tablo 5.2.b KNN algoritması performans sonuçları

Performans Sonuçları	Yüzde (%)
Ort. Accuracy (%)	73.3
Ort. Precision (%)	73.3
Ort. Recall (%)	73.3
Ort. F1-Skor (%)	73.1

kNN, %73.3 Doğruluk değeriyle, SVM'e yakın ancak biraz daha düşük bir performans göstermiştir. Tüm metriklerin birbirine yakın olması (Precision %73.3, Recall %73.3, F1-Skor %73.1), modelin sınıflar arasında dengeli ancak orta düzeyde bir başarıya sahip olduğunu gösterir. kNN'in performansı, her bir test örneğinin sınıfını belirlemek için sadece en yakın 10 komşuya (k=10 varsayılırsa) dayanması nedeniyle, tüm veri setindeki küresel ilişkileri öğrenen Neural Network ve SVM kadar yüksek olamamıştır.

5.3. SVM Algoritması

Tablo 5.13.a SVM algoritması karmaşıklık matrisi

		Tahmini Sınıf		
		Blue	**Brown**	**Green**
Gerçek Sınıf	**Blue**	**766**	50	211
	Brown	114	**876**	**185**
	Green	161	**99**	**745**

Tablo 5.2.b SVM algoritması performans sonuçları

Performans Sonuçları	Yüzde (%)
Ort. Accuracy (%)	74.4
Ort. Precision (%)	75.3
Ort. Recall (%)	74.4
Ort. F1-Skor (%)	74.7

5.2.b'deki sonuçlar incelendiğinde, SVM'in %74.4 Doğruluk (Accuracy) değeri ile Neural Network'ten (%88.0) belirgin şekilde düşük, ancak kNN'den (%73.3) daha iyi bir başarı sergilediği görülmektedir. Precision (%75.3) değerinin Recall (%74.4) değerinden biraz daha yüksek olması, modelin tahminlerinde nispeten daha temkinli olduğunu, yani yaptığı pozitif tahminlerin büyük kısmının gerçekten doğru olduğunu gösterir. F1-Skoru'nun %74.7 olması ise, modelin iyi bir denge sağladığını, fakat üç göz rengi sınıfını ayırt etmede Neural Network'ün derin öğrenme gücüne ulaşamadığını ifade eder.

6. SONUÇLAR

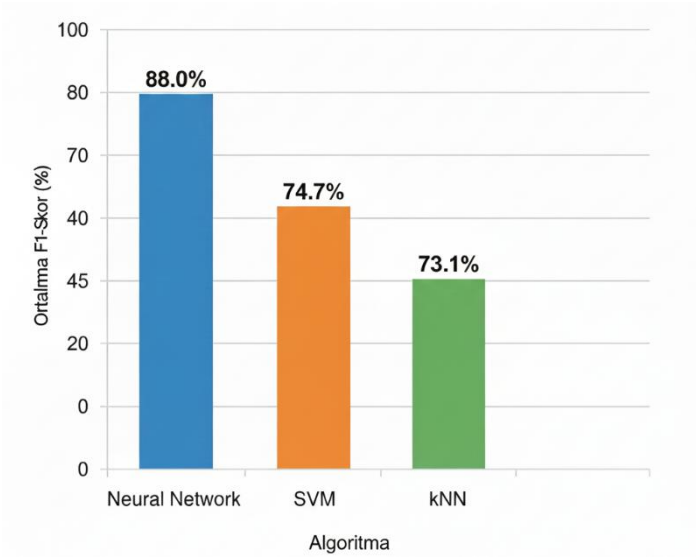
Tablo 6.a Kullanılan tüm algoritmalar için ortalama performans sonuçları

Performans Ölçümleri	Ortalama Accuracy (%)	Ortalama Precision (%)	Ortalama Recall (%)	Ortalama F1-Skor (%)
Neural Network	88.0	88.0	88.0	88.0
SVM	74.4	75.3	74.4	74.7
KNN	73.3	73.3	73.3	73.1

Tablo 6.a incelendiğinde, algoritmaların performans sıralaması net bir şekilde ortaya çıkmaktadır:

1. Neural Network: Tüm metriklerde açık ara en yüksek performansı sergileyerek %88.0 Accuracy ve F1-Skor ile birinci sırada yer almıştır. Derin öğrenme tabanlı özniteliklerin karmaşıklığını en iyi şekilde yakalayabildiği gözlemlenmiştir.
2. SVM: %74.4 Accuracy ve %74.7 F1-Skor ile ikinci en iyi algoritma olmuştur. Doğrusal olmayan ayrım yapabilme yeteneği sayesinde, kNN'den daha yüksek sonuçlar üretmiştir.
3. kNN: %73.3 Accuracy ve %73.1 F1-Skor ile SVM'e yakın ancak üçüncü sırada yer alan bir performans göstermiştir. Basit komşuluk temelli yapısına rağmen, Image Embedding ile dönüştürülmüş veriler üzerinde kabul edilebilir sonuçlar vermiştir.

Grafik 6. kullanılan algoritmaların ortalama F1-Skor değerlerini görselleştirerek performans karşılaştırmasını daha anlaşılır kılmaktadır.



Bu projenin nihai sonuçları, göz rengi sınıflandırma görevinde Derin Öğrenme mimarilerinin (Neural Network), geleneksel makine öğrenimi yaklaşımlarına kıyasla çok daha üstün ve güvenilir sonuçlar ürettiğini göstermiştir. Özellikle SqueezeNet gibi önceden eğitilmiş modellerden elde edilen özniteliklerin, Neural Network gibi algoritmalar tarafından etkin bir şekilde işlenmesi, yüksek doğruluk oranlarına ulaşılmasında kritik bir faktör olmuştur. Bu bulgular, benzer görsel sınıflandırma problemlerinde derin öğrenme tabanlı yaklaşımların öncelikli olarak değerlendirilmesi gerektiğine işaret etmektedir.

7. ÖNERİLER

Ulaşılan Neural Network başarısını artırmak için, ResNet gibi daha derin CNN mimarilerinin doğrudan sınıflandırmada kullanılması, Veri Artırma (Data Augmentation) tekniklerinin uygulanması ve kNN ile SVM modelleri için titiz bir hiperparametre optimizasyonu yapılması önerilmektedir.

8. KAYNAKLAR

1. https://tr.pinterest.com/
2. https://www.flickr.com/
3. https://unsplash.com/
4. https://www.aktuelajans.com/modeller/
5. https://orangedatamining.com/
6. Demsar, J., Curk, T., Erjavec, A., Gorup, A., Hocevar, T., Milutinovic, M., ... & Zupan, B. (2013). Orange: Data mining toolbox in Python. *The Journal of Machine Learning Research, 14*(1), 234-245. (Orange'ın teknik ve akademik tanıtımı için resmi makale).
7. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. (SqueezeNet, ResNet gibi modellerin mimarisini ve Image Embedding yöntemini dolaylı olarak destekler).
8. Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management, 45*(4), 427-437. (Accuracy, Precision, Recall, F1-Skor açıklamaları için).
9. **[1.6]** Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). **ImageNet Classification with Deep Convolutional Neural Networks**. *Advances in Neural Information Processing Systems (NIPS)*, 1097-1105. *(Derin Öğrenme temellerini temsil eder)*